Discriminante lineal de Fisher: desarrollo matemático y resultados preliminares

Álgebra Lineal Aplicada — Entrega parcial del proyecto

Integrantes: (completar)

Noviembre 2026

1. Problema

Tenemos observaciones $x_i \in \mathbb{R}^p$ con etiqueta de clase. Queremos una dirección $w \in \mathbb{R}^p$ tal que, al proyectar $y = w^\top x$, las dos clases queden **lo más separadas posible** y cada clase **lo más compacta posible**. Solo importa la dirección de w.

Notación para dos clases $\mathcal{C}_1, \mathcal{C}_2$: medias μ_k, dispersiones $S_k = \sum_{x \in \mathcal{C}_k} (x - \mu_k)(x - \mu_k)^\top$, y dispersión intraclase $S_W = S_1 + S_2$. Sea $d = \mu_1 - \mu_2$.

Por qué no basta la distancia entre medias. Maximizar $(w^\top d)^2$ no tiene máximo (basta escalar w) y, aun normalizando $\|w\| = 1$, la solución $w \propto d$ ignora la forma de las nubes: si hay correlación, proyectar sobre d puede mezclar las clases.

2. Criterio de Fisher

Como $w^\top S_W w = \sum_k \sum_{x \in \mathcal{C}_k} (w^\top x - w^\top \mu_k)^2$, el denominador es la dispersión intraclase proyectada. Definimos

$$J(w) = \frac{(w^\top (\mu_1 - \mu_2))^2}{w^\top S_W w}, \qquad w \neq 0.$$

Propiedades. (i) $J(cw) = J(w)$ para $c \neq 0$: solo cuenta la dirección; en particular w y $-w$ son equivalentes. (ii) S_W es simétrica y semidefinida positiva, pues $w^\top S_W w$ es una suma de cuadrados ≥ 0. Supondremos $S_W \succ 0$ (se relaja en la sección 6).

3. Teorema y demostración

Teorema. Si $S_W \succ 0$ y $d \neq 0$, los maximizadores de J son exactamente $w = c\, S_W^{-1} d$ con $c \neq 0$, y

$$\max J = d^\top S_W^{-1} d \quad \text{(distancia de Mahalanobis al cuadrado)}.$$

Demostración. Como $S_W \succ 0$ define un producto interno $\langle u, v\rangle_W = u^\top S_W v$. Sea $v = S_W^{1/2} w$. Entonces $w^\top d = v^\top S_W^{-1/2} d$ y $w^\top S_W w = \|v\|^2$, de modo que

$$J = \frac{(v^\top a)^2}{\|v\|^2}, \quad a = S_W^{-1/2} d.$$

Por Cauchy–Schwarz, $(v^\top a)^2 \le \|v\|^2 \|a\|^2$, con igualdad si y solo si $v = ca$. Luego $J \le \|a\|^2 = d^\top S_W^{-1} d$ y la igualdad ocurre para $v = c S_W^{-1/2} d$, es decir $w = S_W^{-1/2} v = c\, S_W^{-1} d$. ■

Casos. Si $S_W = \sigma^2 I$, entonces $w \propto d$ (diferencia de medias): no hay correlación que corregir. Si $d = 0$, $J \equiv 0$ y no hay dirección preferida. En la práctica resolvemos el sistema $S_W w = d$ sin calcular S_W^{-1}.

4. Formulación de Rayleigh y varias clases

Como $(w^\top d)^2 = w^\top S_B w$ con $S_B = d d^\top$ (rango ≤ 1),

$$J(w) = \frac{w^\top S_B w}{w^\top S_W w}, \qquad S_B w = \lambda S_W w,$$

un cociente de Rayleigh *generalizado*. Con $S_W \succ 0$, el problema equivale a los autovalores de la matriz simétrica $S_W^{-1/2} S_B S_W^{-1/2}$ (similar a $S_W^{-1} S_B$), y J máximo es el mayor autovalor $\lambda_{\max}$. Aquí $\lambda_{\max} = d^\top S_W^{-1} d$, lo que coincide con el teorema.

Para K clases, con n_k, μ_k, media global μ y $S_B = \sum_k n_k (\mu_k - \mu)(\mu_k - \mu)^\top$, las direcciones son los autovectores generalizados de mayores autovalores. Como $\sum_k n_k (\mu_k - \mu) = 0$, $\operatorname{rango}(S_B) \le K - 1$; hay a lo sumo $\min\{p, K-1\}$ direcciones útiles (verificado en `test_rank_SB_multiclass`).

5. Ejemplo calculable a mano

$\mathcal{C}_1 = \{(1,1), (2,1), (2,2)\}$, $\mathcal{C}_2 = \{(4,3), (5,3), (5,4)\}$.

Paso	Resultado
Medias	$\mu_1 = (5/3, 4/3)$, $\mu_2 = (14/3, 10/3)$, $d = (-3, -2)$
Dispersión	$S_1 = S_2 = \begin{pmatrix} 2/3 & 1/3 \\ 1/3 & 2/3 \end{pmatrix}$, $S_W = \begin{pmatrix} 4/3 & 2/3 \\ 2/3 & 4/3 \end{pmatrix}$
Sistema $S_W w = d$	$\begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix} w = \begin{pmatrix} -9 \\ -6 \end{pmatrix} \Rightarrow w = (-2, -\frac{1}{2}) \propto (4, 1)$
Proyección $y = 4x_1 + x_2$	$\mathcal{C}_1 \mapsto \{5, 9, 10\}$, $\mathcal{C}_2 \mapsto \{19, 23, 24\}$

Paso	Resultado
Medias proyectadas y umbral	$m_1 = 8$, $m_2 = 22$, $t = 15$

Regla: $4x_1 + x_2 < 15 \Rightarrow \mathcal{C}_1$. Además $J_{\max} = d^\top S_W^{-1} d = 7$, igual al valor calculado numéricamente. Es una verificación de la teoría, no una medida de generalización, porque se clasifican los mismos puntos con que se ajustó.

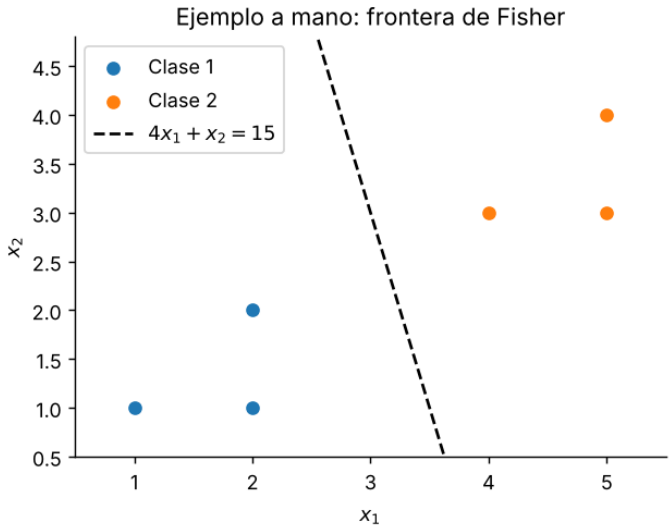


Figure 1: Ejemplo a mano

6. Singularidad y regularización

S_W tiene rango a lo sumo $\min(p, N - K)$; es singular si $N - K < p$ o hay variables redundantes. Si $d = d_R + d_0$ con $d_R \in \operatorname{im} S_W$, $d_0 \in \ker S_W$ y $d_0 \neq 0$, el cociente no tiene máximo finito (direcciones con dispersión intraclase cero pero separación positiva). Se regulariza:

$$S_{W,\lambda} = S_W + \lambda I, \quad w_\lambda = (S_W + \lambda I)^{-1} d, \quad \lambda = \gamma \operatorname{tr}(S_W)/p.$$

Esto maximiza el criterio *modificado*. Para λ grande, w_λ se aproxima a d (el caso $\sigma^2 I$). Elegimos γ solo con validación dentro del entrenamiento.

7. Resultados preliminares

Todo es reproducible con `python experiments/run_all.py` (semillas $2026 + k$, $k = 0, \ldots, 9$).

Experimento A: gaussianas correlacionadas. $\mu_1 = (0, 0)$, $\mu_2 = (1, 0)$, $\Sigma = \begin{pmatrix} 4 & 1.8 \\ 1.8 & 1 \end{pmatrix}$ (definida positiva: $\det = 2.76$). 150 puntos por clase; división 50 % entrenamiento / 50 % prueba hecha antes del ajuste. Misma regla de umbral (punto medio

de medias proyectadas de entrenamiento) para las tres direcciones. J se informa con S_W reemplazada por $\hat{\Sigma} = S_W/(N-2)$ (así no depende de N); el valor poblacional máximo es $\Delta^\top \Sigma^{-1} \Delta = 1/0.76 \approx 1.32$.

Método	J (train)	Exactitud (prueba)	Ángulo con Fisher
Diferencia de medias	0.27 ± 0.11	0.579 ± 0.034	60.1° ± 6.8°
Fisher	**1.19 ± 0.21**	**0.695 ± 0.032**	0°
PCA (PC1)	0.20 ± 0.12	0.559 ± 0.038	83.9° ± 2.8°

(media ± desv. estándar en 10 repeticiones). Fisher gana en las 10 repeticiones de este escenario. La PC1 apunta a la dirección de máxima varianza (la diagonal de la nube), irrelevante para separar. La dirección de Fisher coincide con `LinearDiscriminantAnalysis(solver="lsqr")` de scikit-learn (diferencia $\sim 10^{-16}$). Matriz de confusión (repetición 0, fila = real): Fisher $\begin{pmatrix} 52 & 20 \\ 20 & 58 \end{pmatrix}$, diferencia de medias $\begin{pmatrix} 44 & 28 \\ 32 & 46 \end{pmatrix}$, PC1 $\begin{pmatrix} 44 & 28 \\ 35 & 43 \end{pmatrix}$.

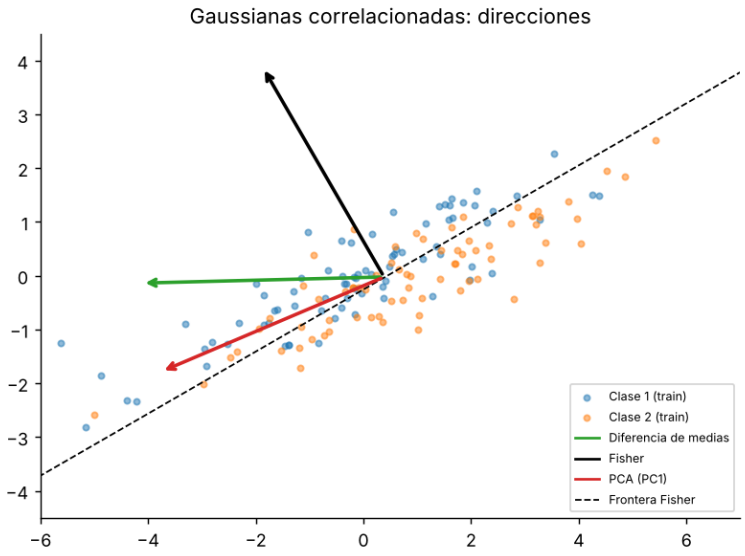


Figure 2: Direcciones y frontera (repetición 0)

Experimento B: pocas muestras y variable redundante. $p = 40$ variables (2 informativas, 1 copia ruidosa de x_1, 37 de ruido), solo $N = 30$ de entrenamiento y 1000 de prueba; $\mu_2 = (1.5, 0)$ en las dos primeras. Aquí rango$(S_W) \leq N - 2 = 28 < 40$: en la repetición 0, S_W tiene 12 autovalores nulos y número de condición $\sim 10^{18}$.

γ	0	10^{-4}	10^{-2}	0.1	1	3
Exactitud (prueba)	0.513	0.547	0.552	0.571	0.605	0.626

Sin regularización ($\gamma = 0$) el sistema es numéricamente inestable y el resultado es casi azar (0.51). La exactitud mejora con γ hasta el mayor valor de la rejilla. El γ elegido por validación cruzada (5 pliegues, dentro del entrenamiento) logra 0.601 ± 0.03 en

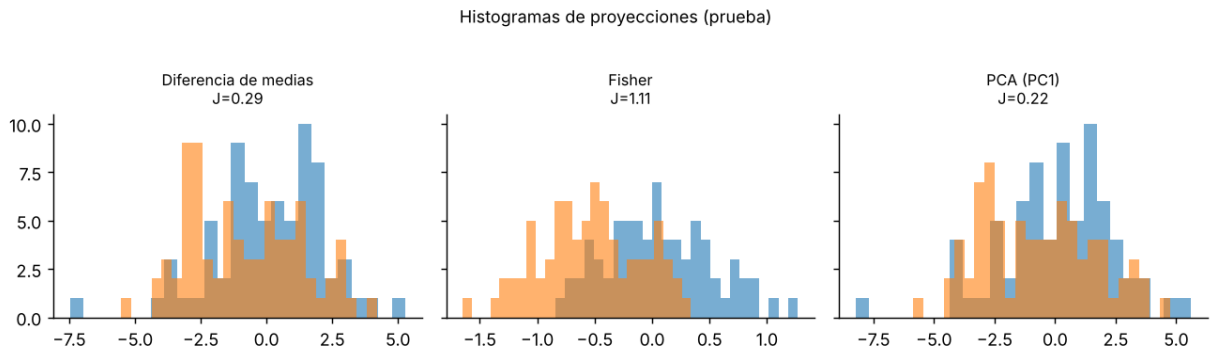


Figure 3: Histogramas de proyecciones en prueba

prueba, algo por debajo del mejor γ fijo de la rejilla, ya que la validación con 30 puntos es ruidosa y eligió valores distintos en cada repetición (de 10^{-4} a 3).

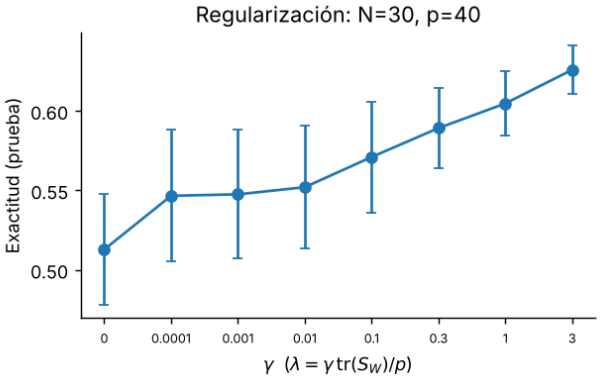


Figure 4: Regularización

8. Limitaciones y trabajo restante

- Los datos son sintéticos y cumplen el supuesto de covarianza común; falta probar covarianzas distintas (donde aparece QDA), clases no separables linealmente y etiquetas ruidosas. **No se concluye que Fisher domine siempre.**
- La rejilla de γ termina en 3 y el mejor valor está en el borde: para la entrega final, ampliarla.
- Para $\gamma = 0$ usamos `solve` sobre una matriz casi singular; una comparación con pseudoinversa queda pendiente.
- Pendiente: un conjunto de datos real y el caso multiclase con datos reales.

9. Relación con LDA probabilístico

Si $X \mid Y = k \sim \mathcal{N}(\mu_k, \Sigma)$ con priors π_k, la regla de Bayes maximiza $\delta_k(x) = x^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k$, afín en x: fronteras lineales. Para dos clases la normal es $\Sigma^{-1}(\mu_1 -$

$\mu_2)$, la misma dirección de Fisher al estimar Σ con la covarianza agrupada. Dos motivaciones, una misma dirección.

Referencias

1. R. A. Fisher (1936), *The Use of Multiple Measurements in Taxonomic Problems*, Annals of Eugenics 7(2).
2. T. Hastie, R. Tibshirani, J. Friedman (2009), *The Elements of Statistical Learning*, cap. 4.
3. C. Bishop (2006), *Pattern Recognition and Machine Learning*, sec. 4.1.4.
4. scikit-learn, *Linear and Quadratic Discriminant Analysis*.
5. Material del curso: «Separación de clases con el discriminante de Fisher».