Discriminante lineal de Fisher: desarrollo matemático y resultados preliminares

Álgebra Lineal Aplicada — Entrega parcial del proyecto

Elison Sanchez, Rodolfo Brandariz, Marcelo Bravo y Marcelo Torres

Noviembre 2026

1. Problema

Tenemos datos $x_i \in \mathbb{R}^p$ y sabemos a cuál de dos clases pertenece cada uno. La idea es reemplazar cada dato por un solo número, $y = w^\top x$, eligiendo w de manera que en esa recta las dos clases queden separadas y, a la vez, cada clase quede lo más agrupada posible. Como veremos, lo único que importa es la dirección de w, no su tamaño.

Objetivo. Nuestro objetivo es programar el discriminante de Fisher para dos clases y comprobar cuatro cosas concretas. Primero, que el código da los mismos valores que el ejemplo hecho a mano ($w \propto (4, 1)$, umbral 15 y $J = 7$). Segundo, que la dirección que obtenemos es la misma que la de `LinearDiscriminantAnalysis` de scikit-learn. Tercero, que con datos gaussianos correlacionados Fisher acierta más en el conjunto de prueba que la diferencia de medias y que PCA, en promedio sobre 10 repeticiones. Y cuarto, que cuando S_W es singular (más variables que datos) regularizar con $S_W + \lambda I$ mejora el resultado, siempre que λ se elija mirando solo el entrenamiento. Todo esto se puede revisar con las pruebas de la carpeta `tests/` y con las tablas que genera `experiments/run_all.py`.

Alcance. Hicimos completo el caso de dos clases: la teoría, el código y los experimentos. El caso de más clases solo lo vemos en la teoría y en una prueba sobre el rango de S_B. Todos los datos son sintéticos, gaussianos y con la misma covarianza en las dos clases; no trabajamos con datos reales, con covarianzas distintas (eso llevaría a QDA) ni con clases que no se puedan separar con una recta.

Conexión con el curso. Todo el problema se resuelve con herramientas de álgebra lineal:

- proyectar un dato sobre una recta es un **producto interno**, $y = w^\top x$;
- el criterio de Fisher es un cociente de **formas cuadráticas** con matrices **simétricas semidefinidas positivas** (S_W y S_B);
- el máximo se demuestra con la **desigualdad de Cauchy–Schwarz** (sección 3);
- calcular w es resolver un **sistema lineal**, $S_W w = \mu_1 - \mu_2$, sin invertir la matriz;
- el caso de varias clases es un **problema de autovalores generalizados**, $S_B w = \lambda S_W w$ (sección 4);

- con pocos datos, S_W tiene **rango** menor que p, es **singular** y está mal **condicionada**; se corrige con la **regularización** $S_W + \lambda I$ (secciones 6 y 7).

Notación para dos clases $\mathcal{C}_1, \mathcal{C}_2$: medias μ_k, dispersiones $S_k = \sum_{x \in \mathcal{C}_k} (x - \mu_k)(x - \mu_k)^\top$, y dispersión intraclase $S_W = S_1 + S_2$. Sea $d = \mu_1 - \mu_2$.

Por qué no basta la distancia entre medias. Lo primero que se nos ocurre es buscar el w que aleje más las medias proyectadas, es decir, maximizar $(w^\top d)^2$. El problema es que eso no tiene máximo: si duplicamos w, el valor se multiplica por cuatro. Podríamos fijar $\|w\| = 1$, y entonces la respuesta sería $w \propto d$, pero esa dirección no toma en cuenta la forma de las nubes de puntos. Cuando las variables están correlacionadas, proyectar sobre d puede hacer que las dos clases se encimen.

2. Criterio de Fisher

Como $w^\top S_W w = \sum_k \sum_{x \in \mathcal{C}_k} (w^\top x - w^\top \mu_k)^2$, el denominador es la dispersión intraclase proyectada. Siguiendo a Fisher [1] (ver también [3], [5]), definimos

$$J(w) = \frac{(w^\top (\mu_1 - \mu_2))^2}{w^\top S_W w}, \qquad w \neq 0.$$

Propiedades. Hay dos cosas que conviene notar. La primera es que si multiplicamos w por cualquier $c \neq 0$, el numerador y el denominador se multiplican por c^2, así que $J(cw) = J(w)$: solo importa la dirección, y por eso w y $-w$ dan lo mismo. La segunda es que S_W es simétrica y semidefinida positiva, porque $w^\top S_W w$ es una suma de cuadrados y nunca es negativa. Por ahora vamos a suponer que S_W es definida positiva (invertible); en la sección 6 vemos qué pasa cuando no lo es.

3. Teorema y demostración

Teorema. Si $S_W \succ 0$ y $d \neq 0$, los maximizadores de J son exactamente $w = c\, S_W^{-1} d$ con $c \neq 0$, y

$$\max J = d^\top S_W^{-1} d.$$

Este valor es proporcional a la distancia de Mahalanobis al cuadrado entre las medias: si $\hat{\Sigma} = S_W/(N-2)$ es la covarianza agrupada, entonces $d^\top S_W^{-1} d = d^\top \hat{\Sigma}^{-1} d/(N-2)$.

Demostración. Como S_W es simétrica, por el teorema espectral se puede escribir $S_W = Q \Lambda Q^\top$, con Q ortogonal y Λ diagonal con los autovalores. Como además es definida positiva, todos los autovalores son positivos, así que existe $S_W^{1/2} = Q \Lambda^{1/2} Q^\top$, que también es simétrica, definida positiva e invertible, y cumple $S_W^{1/2} S_W^{1/2} = S_W$. Sea

$v = S_W^{1/2} w$. Entonces $w^\top d = v^\top S_W^{-1/2} d$ y $w^\top S_W w = \|v\|^2$, de modo que

$$J = \frac{(v^\top a)^2}{\|v\|^2}, \quad a = S_W^{-1/2} d.$$

Por Cauchy–Schwarz, $(v^\top a)^2 \le \|v\|^2 \|a\|^2$, con igualdad si y solo si $v = ca$. Luego $J \le \|a\|^2 = d^\top S_W^{-1} d$ y la igualdad ocurre para $v = c S_W^{-1/2} d$, es decir $w = S_W^{-1/2} v = c\, S_W^{-1} d$. ■

Casos. Si $S_W = \sigma^2 I$, entonces $w \propto d$ (diferencia de medias): no hay correlación que corregir. Si $d = 0$, $J \equiv 0$ y no hay dirección preferida; en ese caso el código lanza un error en lugar de devolver un vector sin sentido. En la práctica resolvemos el sistema $S_W w = d$ (con `np.linalg.solve`, que usa una factorización LU) en lugar de calcular S_W^{-1} y multiplicar: calcular la inversa hace más operaciones y acumula más error de redondeo, sobre todo cuando S_W está mal condicionada, y no la necesitamos para nada más.

4. Formulación de Rayleigh y varias clases

Como $(w^\top d)^2 = w^\top S_B w$ con $S_B = d d^\top$ (rango ≤ 1),

$$J(w) = \frac{w^\top S_B w}{w^\top S_W w}, \qquad S_B w = \lambda S_W w.$$

Esto es un cociente de Rayleigh *generalizado*. Si S_W es invertible, podemos hacer el mismo cambio de la demostración, $v = S_W^{1/2} w$, y el problema pasa a ser encontrar los autovalores de la matriz simétrica $S_W^{-1/2} S_B S_W^{-1/2}$. Esta matriz tiene los mismos autovalores que $S_W^{-1} S_B$, porque son semejantes. El valor máximo de J es entonces el autovalor más grande. En el caso de dos clases se puede calcular directamente: como $S_B = d d^\top$ tiene rango 1, la matriz $S_W^{-1} S_B = S_W^{-1} d d^\top$ también tiene rango 1, así que tiene un solo autovalor distinto de cero. Para encontrarlo basta probar con $w = S_W^{-1} d$:

$$S_W^{-1} d d^\top (S_W^{-1} d) = (d^\top S_W^{-1} d)\, S_W^{-1} d,$$

de modo que $S_W^{-1} d$ es autovector con autovalor $d^\top S_W^{-1} d$. Es justo el máximo y la dirección que obtuvimos en el teorema.

Para K clases, con n_k, μ_k, media global μ y $S_B = \sum_k n_k (\mu_k - \mu)(\mu_k - \mu)^\top$, las direcciones son los autovectores generalizados de mayores autovalores [2], [5]. Como $\sum_k n_k (\mu_k - \mu) = 0$, rango$(S_B) \le K - 1$; hay a lo sumo $\min\{p, K-1\}$ direcciones útiles (verificado en `test_rank_SB_multiclass`).

5. Ejemplo calculable a mano

$\mathcal{C}_1 = \{(1,1),(2,1),(2,2)\}, \mathcal{C}_2 = \{(4,3),(5,3),(5,4)\}$.

Paso	Resultado
Medias	$\mu_1 = (5/3, 4/3)$, $\mu_2 = (14/3, 10/3)$, $d = (-3,-2)$
Dispersión	$S_1 = S_2 = \begin{pmatrix} 2/3 & 1/3 \\ 1/3 & 2/3 \end{pmatrix}$, $S_W = \begin{pmatrix} 4/3 & 2/3 \\ 2/3 & 4/3 \end{pmatrix}$
Sistema $S_W w = d$	$\begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix} w = \begin{pmatrix} -9 \\ -6 \end{pmatrix} \Rightarrow w = (-2, -\frac{1}{2}) \propto (4,1)$
Proyección $y = 4x_1 + x_2$	$\mathcal{C}_1 \mapsto \{5,9,10\}$, $\mathcal{C}_2 \mapsto \{19,23,24\}$
Medias proyectadas y umbral	$m_1 = 8$, $m_2 = 22$, $t = 15$

Regla: $4x_1 + x_2 < 15 \Rightarrow \mathcal{C}_1$. Además $J_{\text{max}} = d^\top S_W^{-1} d = 7$, igual al valor calculado numéricamente. Es una verificación de la teoría, no una medida de generalización, porque se clasifican los mismos puntos con que se ajustó.

Por qué el umbral va en el punto medio. Fisher solo da la dirección w; el umbral es una decisión aparte. Usamos el punto medio $t = \frac{1}{2}(w^\top \mu_1 + w^\top \mu_2)$ porque es la regla óptima cuando las dos clases son gaussianas con la misma covarianza, tienen la misma probabilidad previa y equivocarse en un sentido cuesta lo mismo que en el otro. En ese caso (sección 9), la regla de Bayes compara $\delta_1(x) - \delta_2(x) = w^\top x - \frac{1}{2} w^\top (\mu_1 + \mu_2)$ con cero, usando $w = \Sigma^{-1}(\mu_1 - \mu_2)$; eso es exactamente comparar $w^\top x$ con el punto medio. Si las clases tuvieran probabilidades previas distintas, el umbral se movería en $\log(\pi_2/\pi_1)$.

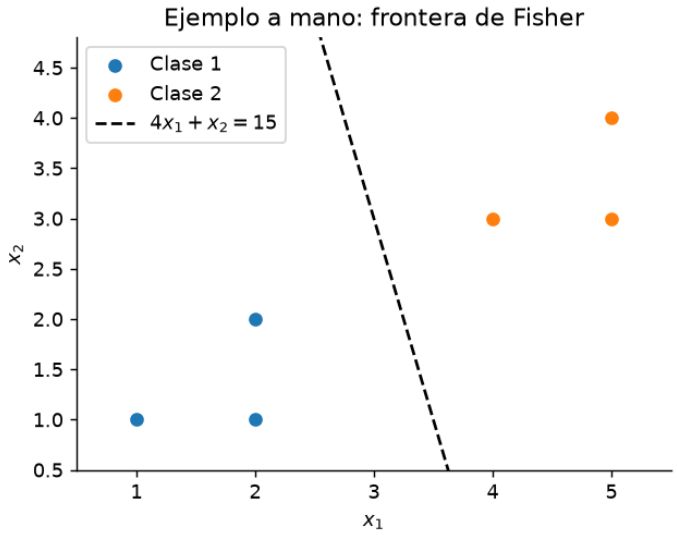


Figura 1: Ejemplo a mano

6. Singularidad y regularización

S_W tiene rango a lo sumo $\min(p, N - K)$; es singular si $N - K < p$ o hay variables redundantes. Si $d = d_R + d_0$ con $d_R \in \text{im}\, S_W$, $d_0 \in \ker S_W$ y $d_0 \neq 0$, el cociente no tiene máximo finito (direcciones con dispersión intraclase cero pero separación positiva). Se regulariza:

$$S_{W,\lambda} = S_W + \lambda I, \quad w_\lambda = (S_W + \lambda I)^{-1} d, \quad \lambda = \gamma \,\text{tr}(S_W)/p.$$

Escalamos λ con $\text{tr}(S_W)/p$, que es el promedio de los autovalores de S_W, es decir, la dispersión típica por variable. Así γ no tiene unidades: si multiplicamos todos los datos por una constante c, S_W y $\text{tr}(S_W)$ se multiplican por c^2, λ cambia igual y la dirección w_λ no cambia. Además, γ dice directamente cuánto pesa λI frente a S_W: con $\gamma = 1$, el término agregado es del mismo tamaño que la dispersión promedio. Hay que tener claro que así ya no se maximiza el criterio original, sino uno modificado [5]. Cuando λ es muy grande, el término λI domina sobre S_W y w_λ apunta casi en la dirección de d, como en el caso $S_W = \sigma^2 I$. El valor de γ lo elegimos solo con validación dentro del entrenamiento.

7. Resultados preliminares

Todo es reproducible con `python experiments/run_all.py` (semillas $2026 + k$, $k = 0, \ldots, 9$).

Experimento A: gaussianas correlacionadas. $\mu_1 = (0, 0)$, $\mu_2 = (1, 0)$, $\Sigma = \begin{pmatrix} 4 & 1.8 \\ 1.8 & 1 \end{pmatrix}$ (definida positiva: $\det = 0.76$). 150 puntos por clase; división 50 %

entrenamiento / 50 % prueba hecha antes del ajuste. Misma regla de umbral (punto medio de medias proyectadas de entrenamiento) para las tres direcciones. Para reportar J usamos $\hat{\Sigma} = S_W/(N-2)$ en lugar de S_W. La razón es que S_W es una suma sobre todos los puntos y crece con N, mientras que $\hat{\Sigma}$ es la covarianza agrupada y no depende del tamaño de la muestra; así el valor se puede comparar con el teórico. Con $\Delta = \mu_1 - \mu_2 = (-1, 0)$, el máximo teórico es $\Delta^\top \Sigma^{-1} \Delta = 1/0.76 \approx 1.32$.

Método	J (train)	Exactitud (prueba)	Ángulo con Fisher
Diferencia de medias	0.27 ± 0.11	0.579 ± 0.034	60.1° ± 6.8°
Fisher	**1.19 ± 0.21**	**0.695 ± 0.032**	0°
PCA (PC1)	0.20 ± 0.12	0.559 ± 0.038	83.9° ± 2.8°

(media ± desv. estándar en 10 repeticiones). Fisher gana en las 10 repeticiones de este escenario. La PC1 apunta a la dirección de máxima varianza (la diagonal de la nube), irrelevante para separar. La dirección de Fisher coincide con `LinearDiscriminantAnalysis` de scikit-learn [4], con `solver="lsqr"` (diferencia $\sim 10^{-16}$). Matriz de confusión (repetición 0, fila = real): Fisher $\begin{pmatrix} 52 & 20 \\ 20 & 58 \end{pmatrix}$, diferencia de medias $\begin{pmatrix} 44 & 28 \\ 32 & 46 \end{pmatrix}$, PC1 $\begin{pmatrix} 44 & 28 \\ 35 & 43 \end{pmatrix}$.

Comparación con el valor teórico. Como generamos los datos nosotros, conocemos sus medias y su covarianza verdaderas, y podemos calcular cuánto acertaría cada dirección con infinitos datos. Al proyectar sobre w, cada clase sigue siendo normal, con medias separadas por $\delta = |w^\top \Delta|$ y desviación $\sigma = \sqrt{w^\top \Sigma w}$; con el umbral en el punto medio, la exactitud es

$$\Phi\left(\frac{\delta}{2\sigma}\right),$$

donde Φ es la función de distribución de la normal estándar. Para la dirección de Fisher, δ/σ es la distancia de Mahalanobis $\sqrt{\Delta^\top \Sigma^{-1} \Delta} \approx 1.147$, y la exactitud es $\Phi(0.574) \approx 0.717$, que es la mejor posible con estos datos (la regla de Bayes, sección 9). Para PCA usamos la primera componente de la covarianza total de la mezcla, $\Sigma + \frac{1}{4}\Delta\Delta^\top$.

Método	Exactitud teórica	Exactitud obtenida	Diferencia
Diferencia de medias	0.599	0.579	−0.020
Fisher (óptimo de Bayes)	**0.717**	**0.695**	−0.022
PCA (PC1)	0.582	0.559	−0.023

Los tres métodos quedan cerca de su valor teórico y en el mismo orden, lo que confirma que los resultados tienen sentido. La lectura importante es que Fisher está a solo 2 puntos del máximo posible: el 30 % que falla no es un defecto del método, sino que las dos clases realmente se superponen. La pequeña diferencia que queda en los tres métodos se explica porque las medias, la covarianza y el umbral se estiman con solo 150 puntos de entrenamiento. Del mismo modo, el J de Fisher en el entrenamiento (1.19 ± 0.21)

queda dentro de una desviación estándar del valor teórico 1.32. Estos valores teóricos los calcula `experiments/run_all.py` (en `results/resumen.json`) y la fórmula se verifica en `test_theoretical_accuracy`.

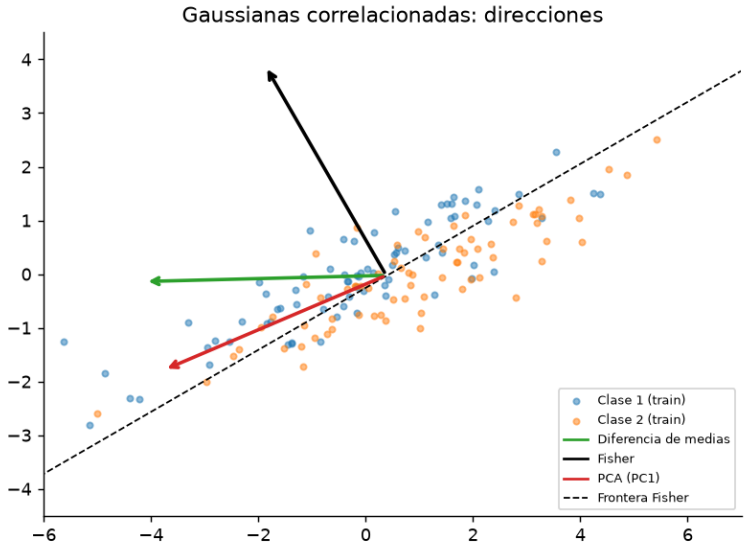


Figura 2: Direcciones y frontera (repetición 0)

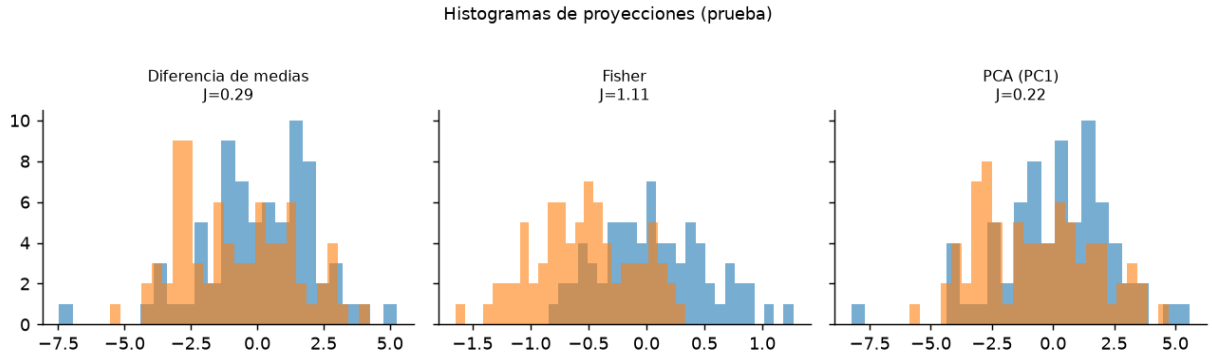


Figura 3: Histogramas de proyecciones en prueba

Experimento B: pocas muestras y variable redundante. $p = 40$ variables (2 informativas, 1 copia ruidosa de x_1, 37 de ruido), solo $N = 30$ de entrenamiento y 1000 de prueba; $\mu_2 = (1.5, 0)$ en las dos primeras. Aquí rango$(S_W) \leq N - 2 = 28 < 40$: en la repetición 0, S_W tiene 12 autovalores nulos y número de condición $\sim 10^{18}$.

γ	Exactitud media (prueba)	Desviación estándar
0	0.513	0.035
10^{-4}	0.547	0.041

γ	Exactitud media (prueba)	Desviación estándar
10^{-3}	0.548	0.041
10^{-2}	0.552	0.039
0.1	0.571	0.035
0.3	0.589	0.025
1	0.605	0.020
3	0.626	0.015
10	0.630	0.010
30	0.629	0.011
100	0.629	0.010

Como referencia, en las mismas 10 repeticiones medimos también:

Método de comparación	Exactitud media (prueba)	Desviación estándar
Pseudoinversa, $w = S_W^+ d$ (sin regularizar)	0.562	0.027
Diferencia de medias, $w \propto d$	0.628	0.010
γ elegido por validación cruzada	0.619	0.020

Sin regularizar ($\gamma = 0$), el sistema es numéricamente inestable y la exactitud media es 0.513, prácticamente al azar. Por eso agregamos al código un aviso que salta cuando el número de condición de S_W pasa de 10^{12}. Con la pseudoinversa la exactitud sube a 0.562. Sin embargo, el material del curso [5] advierte que la pseudoinversa no resuelve el criterio original cuando S_W es singular, porque solo escoge una de muchas direcciones posibles; por eso la incluimos únicamente como comparación.

A medida que aumenta γ, la exactitud sube hasta 0.630 y después se queda casi igual. Esto era de esperar por lo que vimos en la sección 6: con λ grande, w_λ se acerca a la dirección de d, y efectivamente los valores grandes de γ dan casi lo mismo que la diferencia de medias (0.628). Nuestra interpretación es que con solo 30 datos S_W queda muy mal estimada, y conviene apoyarse casi solo en las medias. Ojo: estos valores son de prueba y los mostramos solo para describir el comportamiento; no los usamos para elegir γ.

Cuando elegimos γ con validación cruzada de cinco pliegues, usando solo el entrenamiento, la exactitud media en prueba es 0.619 (desviación estándar 0.020). El γ elegido cambió bastante de una repetición a otra (desde 10^{-4} hasta 100), lo cual tiene sentido: con tan pocos datos, cada pliegue de validación tiene apenas unos 6 puntos y la estimación es ruidosa.

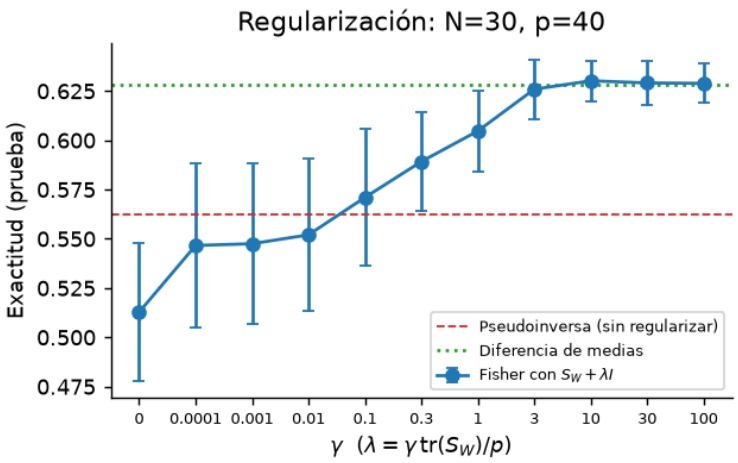


Figura 4: Regularización, pseudoinversa y diferencia de medias

8. Limitaciones y trabajo restante

- Los datos son sintéticos y cumplen el supuesto de covarianza común; falta probar covarianzas distintas (donde aparece QDA), clases no separables linealmente y etiquetas ruidosas. **No se concluye que Fisher domine siempre.**
- En el experimento B el mejor desempeño se parece al de la diferencia de medias, así que con $N < p$ la ventaja de Fisher depende de cuánta regularización se use.
- Pendiente: un conjunto de datos real y el caso multiclase con datos reales.

9. Relación con LDA probabilístico

Si $X \mid Y = k \sim \mathcal{N}(\mu_k, \Sigma)$ con priors π_k, la regla de Bayes maximiza $\delta_k(x) = x^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k$, Esta función es afín en x, así que las fronteras entre clases son rectas (o hiperplanos). Para dos clases, el vector normal a la frontera es $\Sigma^{-1}(\mu_1 - \mu_2)$. Si estimamos Σ con la covarianza agrupada, que es proporcional a S_W, obtenemos la misma dirección que con el criterio de Fisher. Es decir, partiendo de una idea geométrica (Fisher) y de una probabilística (Bayes) se llega al mismo resultado [2], [3].

10. Organización del equipo y contribuciones

El proyecto se desarrolla de manera colaborativa. Las responsabilidades iniciales se distribuyen de la siguiente manera:

Integrante	Responsabilidad principal	Actividades
Elison Sanchez	Fundamentos matemáticos	Formulación del criterio de Fisher, demostración matemática y revisión de la notación.
Rodolfo Brandariz	Desarrollo matemático aplicado	Resolución del ejemplo manual, cálculo de matrices de dispersión y explicación de las proyecciones.
Marcelo Bravo	Implementación computacional	Desarrollo y revisión del código Python, implementación del algoritmo y comparación con PCA.
Marcelo Torres	Experimentación y documentación	Experimentos de regularización, análisis de resultados, gráficos y documentación del repositorio.

11. Cronograma de actividades

Actividad	Responsable(s)	Fecha límite	Estado
Revisión y corrección matemática	Elison Sanchez y Rodolfo Brandariz	2/11/2026	En revisión
Verificación de la implementación y pruebas	Marcelo Bravo	2/11/2026	En revisión
Actualización de experimentos y resultados	Marcelo Bravo y Marcelo Torres	2/11/2026	En revisión
Interpretación y discusión de resultados	Todos los integrantes	2/11/2026	En revisión
Actualización de documentos y referencias	Rodolfo Brandariz y Marcelo Torres	7/11/2026	En revisión
Preparación y grabación del video	Todos los integrantes	7/11/2026	Pendiente
Verificación final del repositorio y entrega	Todos los integrantes	9/11/2026	Pendiente

Referencias

[1] R. A. Fisher, “The use of multiple measurements in taxonomic problems,” *Annals of Eugenics*, vol. 7, no. 2, pp. 179–188, 1936, doi: 10.1111/j.1469-1809.1936.tb02137.x.

[2] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York, NY, USA: Springer, 2009, ch. 4.

[3] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer, 2006, sec. 4.1.4.

[4] scikit-learn developers, “Linear and Quadratic Discriminant Analysis,” *scikit-learn documentation*. [En línea]. Disponible: https://scikit-learn.org/stable/modules/lda_qda.html. [Accedido: 2 nov. 2026].

[5] O. Velásquez Castañón, “Separación de clases con el discriminante de Fisher: proyecciones, cocientes de Rayleigh y clasificación,” material de referencia, Álgebra Lineal Aplicada 2026-2, Universidad del Pacífico, Lima, Perú, oct. 2026.