Discriminante lineal de Fisher: desarrollo matemático y resultados preliminares

Álgebra Lineal Aplicada — Entrega parcial del proyecto

Elison Sanchez, Rodolfo Brandariz, Marcelo Bravo y Marcelo Torres

Noviembre 2026

1. Problema

Tenemos observaciones $x_i \in \mathbb{R}^p$ con etiqueta de clase. Queremos una dirección $w \in \mathbb{R}^p$ tal que, al proyectar $y = w^\top x$, las dos clases queden **lo más separadas posible** y cada clase **lo más compacta posible**. Solo importa la dirección de w.

Objetivo. Implementar el discriminante de Fisher para dos clases y comprobar que:

1. reproduce el ejemplo a mano ($w \propto (4, 1)$, umbral 15, $J = 7$);
2. su dirección coincide con la de `LinearDiscriminantAnalysis` de scikit-learn;
3. con datos gaussianos correlacionados, tiene mayor exactitud en prueba que la diferencia de medias y que la primera componente principal, en promedio sobre 10 repeticiones;
4. cuando S_W es singular ($N < p$), regularizar con $S_W + \lambda I$ mejora la exactitud en prueba frente a no regularizar, eligiendo λ solo con datos de entrenamiento.

Cada punto se revisa con las pruebas de `tests/` o con las tablas que genera `experiments/run_all.py`.

Alcance. Trabajamos el caso de dos clases completo (teoría, código y experimentos). El caso de varias clases se ve en la teoría y en una prueba de rango. Los datos son sintéticos, gaussianos y con la misma covarianza en ambas clases. No incluimos datos reales, covarianzas distintas (QDA) ni clases que no se puedan separar con una recta.

Notación para dos clases $\mathcal{C}_1, \mathcal{C}_2$: medias μ_k, dispersiones $S_k = \sum_{x \in \mathcal{C}_k} (x - \mu_k)(x - \mu_k)^\top$, y dispersión intraclase $S_W = S_1 + S_2$. Sea $d = \mu_1 - \mu_2$.

Por qué no basta la distancia entre medias. Maximizar $(w^\top d)^2$ no tiene máximo (basta escalar w) y, aun normalizando $\|w\| = 1$, la solución $w \propto d$ ignora la forma de las nubes: si hay correlación, proyectar sobre d puede mezclar las clases.

2. Criterio de Fisher

Como $w^\top S_W w = \sum_k \sum_{x \in \mathcal{C}_k} (w^\top x - w^\top \mu_k)^2$, el denominador es la dispersión intraclase proyectada. Siguiendo a Fisher [1] (ver también [3], [5]), definimos

$$J(w) = \frac{(w^\top(\mu_1 - \mu_2))^2}{w^\top S_W w}, \qquad w \neq 0.$$

Propiedades. (i) $J(cw) = J(w)$ para $c \neq 0$: solo cuenta la dirección; en particular w y $-w$ son equivalentes. (ii) S_W es simétrica y semidefinida positiva, pues $w^\top S_W w$ es una suma de cuadrados ≥ 0. Supondremos $S_W \succ 0$ (se relaja en la sección 6).

3. Teorema y demostración

Teorema. Si $S_W \succ 0$ y $d \neq 0$, los maximizadores de J son exactamente $w = c\, S_W^{-1} d$ con $c \neq 0$, y

$$\max J = d^\top S_W^{-1} d \quad \big(\text{distancia de Mahalanobis al cuadrado}\big).$$

Demostración. Como $S_W \succ 0$ define un producto interno $\langle u, v \rangle_W = u^\top S_W v$. Sea $v = S_W^{1/2} w$. Entonces $w^\top d = v^\top S_W^{-1/2} d$ y $w^\top S_W w = \|v\|^2$, de modo que

$$J = \frac{(v^\top a)^2}{\|v\|^2}, \quad a = S_W^{-1/2} d.$$

Por Cauchy–Schwarz, $(v^\top a)^2 \leq \|v\|^2 \|a\|^2$, con igualdad si y solo si $v = ca$. Luego $J \leq \|a\|^2 = d^\top S_W^{-1} d$ y la igualdad ocurre para $v = c S_W^{-1/2} d$, es decir $w = S_W^{-1/2} v = c\, S_W^{-1} d$. ■

Casos. Si $S_W = \sigma^2 I$, entonces $w \propto d$ (diferencia de medias): no hay correlación que corregir. Si $d = 0$, $J \equiv 0$ y no hay dirección preferida; en ese caso el código lanza un error en lugar de devolver un vector sin sentido. En la práctica resolvemos el sistema $S_W w = d$ sin calcular S_W^{-1}.

4. Formulación de Rayleigh y varias clases

Como $(w^\top d)^2 = w^\top S_B w$ con $S_B = d d^\top$ (rango ≤ 1),

$$J(w) = \frac{w^\top S_B w}{w^\top S_W w}, \qquad S_B w = \lambda S_W w,$$

un cociente de Rayleigh *generalizado*. Con $S_W \succ 0$, el problema equivale a los autovalores de la matriz simétrica $S_W^{-1/2} S_B S_W^{-1/2}$ (similar a $S_W^{-1} S_B$), y J máximo es el mayor autovalor λ_{max}. Aquí $\lambda_{\text{max}} = d^\top S_W^{-1} d$, lo que coincide con el teorema.

Para K clases, con n_k, μ_k, media global μ y $S_B = \sum_k n_k (\mu_k - \mu)(\mu_k - \mu)^\top$, las direcciones son los autovectores generalizados de mayores autovalores [2], [5]. Como $\sum_k n_k (\mu_k - \mu) = 0$, rango$(S_B) \leq K - 1$; hay a lo sumo min$\{p, K-1\}$ direcciones útiles (verificado en `test_rank_SB_multiclass`).

5. Ejemplo calculable a mano

$\mathcal{C}_1 = \{(1,1), (2,1), (2,2)\}, \mathcal{C}_2 = \{(4,3), (5,3), (5,4)\}$.

Paso	Resultado
Medias	$\mu_1 = (5/3, 4/3), \mu_2 = (14/3, 10/3)$, $d = (-3, -2)$
Dispersión	$S_1 = S_2 = \begin{pmatrix} 2/3 & 1/3 \\ 1/3 & 2/3 \end{pmatrix}$, $S_W = \begin{pmatrix} 4/3 & 2/3 \\ 2/3 & 4/3 \end{pmatrix}$
Sistema $S_W w = d$	$\begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix} w = \begin{pmatrix} -9 \\ -6 \end{pmatrix} \Rightarrow w = (-2, -\frac{1}{2}) \propto (4, 1)$
Proyección $y = 4x_1 + x_2$	$\mathcal{C}_1 \mapsto \{5, 9, 10\}, \mathcal{C}_2 \mapsto \{19, 23, 24\}$
Medias proyectadas y umbral	$m_1 = 8, m_2 = 22, t = 15$

Regla: $4x_1 + x_2 < 15 \Rightarrow \mathcal{C}_1$. Además $J_{\text{max}} = d^\top S_W^{-1} d = 7$, igual al valor calculado numéricamente. Es una verificación de la teoría, no una medida de generalización, porque se clasifican los mismos puntos con que se ajustó.

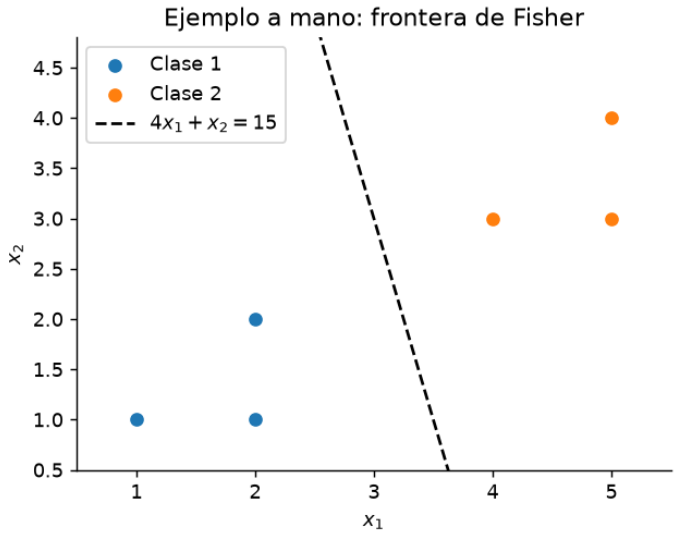


Figura 1: Ejemplo a mano

6. Singularidad y regularización

S_W tiene rango a lo sumo $\min(p, N - K)$; es singular si $N - K < p$ o hay variables redundantes. Si $d = d_R + d_0$ con $d_R \in \text{im}\, S_W$, $d_0 \in \ker S_W$ y $d_0 \neq 0$, el cociente no tiene máximo finito (direcciones con dispersión intraclase cero pero separación positiva). Se regulariza:

$$S_{W,\lambda} = S_W + \lambda I, \quad w_\lambda = (S_W + \lambda I)^{-1} d, \quad \lambda = \gamma \,\text{tr}(S_W)/p.$$

Esto maximiza el criterio *modificado* [5]. Para λ grande, w_λ se aproxima a d (el caso $\sigma^2 I$). Elegimos γ solo con validación dentro del entrenamiento.

7. Resultados preliminares

Todo es reproducible con `python experiments/run_all.py` (semillas $2026 + k$, $k = 0, \ldots, 9$).

Experimento A: gaussianas correlacionadas. $\mu_1 = (0, 0)$, $\mu_2 = (1, 0)$, $\Sigma = \begin{pmatrix} 4 & 1.8 \\ 1.8 & 1 \end{pmatrix}$ (definida positiva: $\det = 0.76$). 150 puntos por clase; división 50 % entrenamiento / 50 % prueba hecha antes del ajuste. Misma regla de umbral (punto medio de medias proyectadas de entrenamiento) para las tres direcciones. J se informa con S_W reemplazada por $\hat{\Sigma} = S_W/(N - 2)$ (así no depende de N); el valor poblacional máximo es $\Delta^\top \Sigma^{-1} \Delta = 1/0.76 \approx 1.32$.

Método	J (train)	Exactitud (prueba)	Ángulo con Fisher
Diferencia de medias	0.27 ± 0.11	0.579 ± 0.034	60.1° ± 6.8°
Fisher	**1.19 ± 0.21**	**0.695 ± 0.032**	0°
PCA (PC1)	0.20 ± 0.12	0.559 ± 0.038	83.9° ± 2.8°

(media ± desv. estándar en 10 repeticiones). Fisher gana en las 10 repeticiones de este escenario. La PC1 apunta a la dirección de máxima varianza (la diagonal de la nube), irrelevante para separar. La dirección de Fisher coincide con `LinearDiscriminantAnalysis` de scikit-learn [4], con `solver="lsqr"` (diferencia $\sim 10^{-16}$). Matriz de confusión (repetición 0, fila = real): Fisher $\begin{pmatrix} 52 & 20 \\ 20 & 58 \end{pmatrix}$, diferencia de medias $\begin{pmatrix} 44 & 28 \\ 32 & 46 \end{pmatrix}$, PC1 $\begin{pmatrix} 44 & 28 \\ 35 & 43 \end{pmatrix}$.

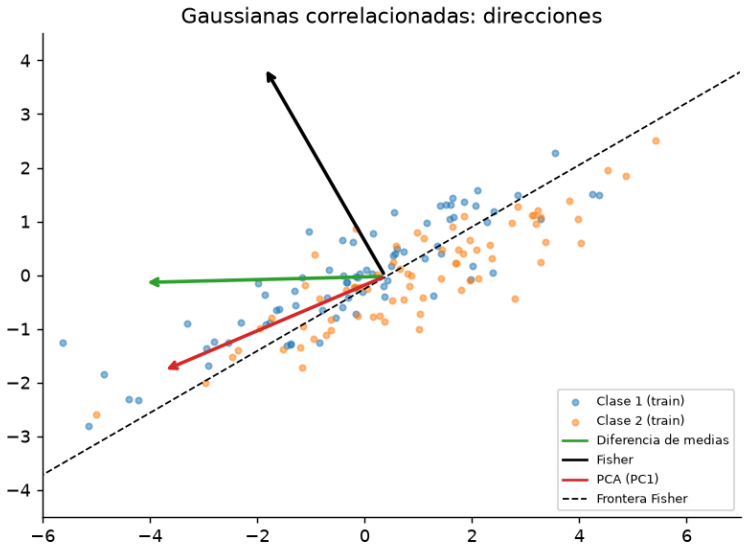


Figura 2: Direcciones y frontera (repetición 0)

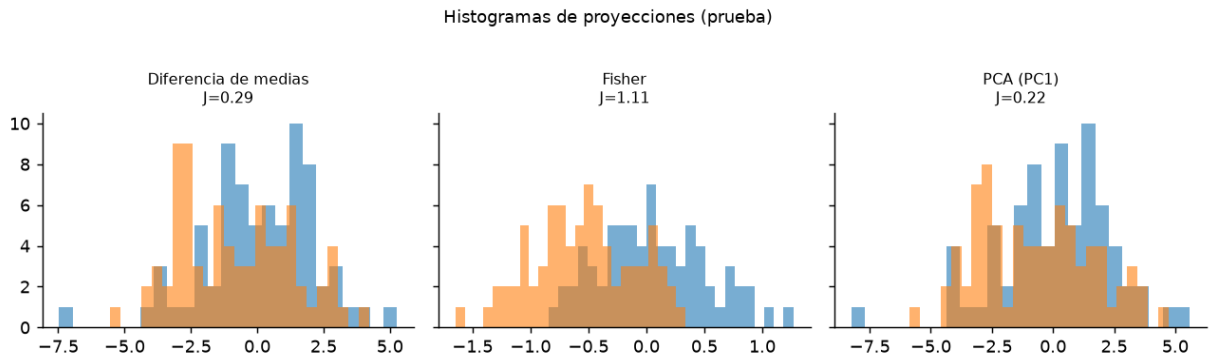


Figura 3: Histogramas de proyecciones en prueba

Experimento B: pocas muestras y variable redundante. $p = 40$ variables (2 informativas,

1 copia ruidosa de x_1, 37 de ruido), solo $N = 30$ de entrenamiento y 1000 de prueba; $\mu_2 = (1.5, 0)$ en las dos primeras. Aquí rango$(S_W) \leq N - 2 = 28 < 40$: en la repetición 0, S_W tiene 12 autovalores nulos y número de condición $\sim 10^{18}$.

γ	Exactitud media (prueba)	Desviación estándar
0	0.513	0.035
10^{-4}	0.547	0.041
10^{-3}	0.548	0.041
10^{-2}	0.552	0.039
0.1	0.571	0.035
0.3	0.589	0.025
1	0.605	0.020
3	0.626	0.015
10	0.630	0.010
30	0.629	0.011
100	0.629	0.010

Como referencia, en las mismas 10 repeticiones medimos también:

Método de comparación	Exactitud media (prueba)	Desviación estándar
Pseudoinversa, $w = S_W^+ d$ (sin regularizar)	0.562	0.027
Diferencia de medias, $w \propto d$	0.628	0.010
γ elegido por validación cruzada	0.619	0.020

Sin regularización ($\gamma = 0$), el sistema es numéricamente inestable y la exactitud media es 0.513, cercana al azar. El código ahora avisa cuando S_W es numéricamente singular (número de condición mayor que 10^{12}). Con la pseudoinversa la exactitud sube a 0.562, pero, como señala [5], esto no resuelve el criterio original cuando S_W es singular: solo elige una de las muchas direcciones posibles, por eso la usamos únicamente para comparar.

Al aumentar γ, la exactitud media crece hasta 0.630 y luego se estabiliza. Esto coincide con la teoría de la sección 6: cuando $\lambda \to \infty$, w_λ tiende a la dirección de d, y de hecho los valores grandes de γ quedan prácticamente iguales a la diferencia de medias (0.628). Con tan pocos datos, S_W se estima mal y lo mejor es apoyarse casi solo en las medias. Estos valores de prueba son descriptivos y no se usan para elegir el parámetro.

El parámetro γ elegido por validación cruzada de cinco pliegues, hecha solo con el entrenamiento, alcanza una exactitud media de 0.619 (desviación estándar 0.020) en prueba. Los valores elegidos variaron entre repeticiones (10^{-4}, 0.3, 1, 3, 10, 30, 100), lo que muestra que la selección es sensible al tamaño reducido de la muestra.

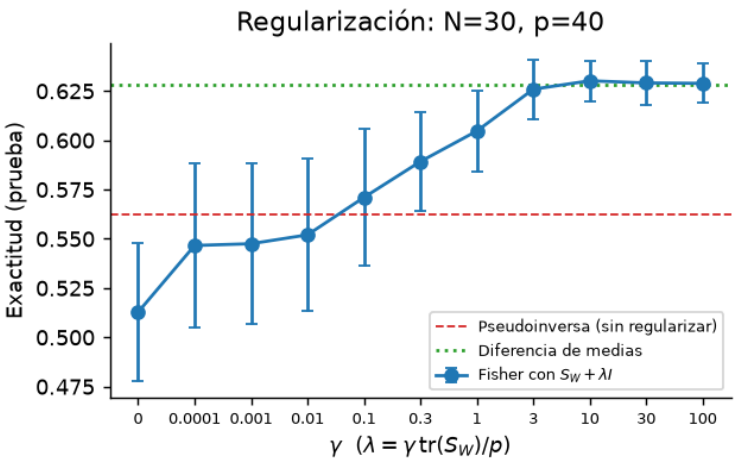


Figura 4: Regularización, pseudoinversa y diferencia de medias

8. Limitaciones y trabajo restante

- Los datos son sintéticos y cumplen el supuesto de covarianza común; falta probar covarianzas distintas (donde aparece QDA), clases no separables linealmente y etiquetas ruidosas. **No se concluye que Fisher domine siempre.**
- En el experimento B el mejor desempeño se parece al de la diferencia de medias, así que con $N < p$ la ventaja de Fisher depende de cuánta regularización se use.
- Pendiente: un conjunto de datos real y el caso multiclase con datos reales.

9. Relación con LDA probabilístico

Si $X \mid Y = k \sim \mathcal{N}(\mu_k, \Sigma)$ con priors π_k, la regla de Bayes maximiza $\delta_k(x) = x^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log \pi_k$, afín en x: fronteras lineales. Para dos clases la normal es $\Sigma^{-1}(\mu_1 - \mu_2)$, la misma dirección de Fisher al estimar Σ con la covarianza agrupada. Dos motivaciones, una misma dirección [2], [3].

10. Organización del equipo y contribuciones

El proyecto se desarrolla de manera colaborativa. Las responsabilidades iniciales se distribuyen de la siguiente manera:

Integrante	Responsabilidad principal	Actividades
Elison Sanchez	Fundamentos matemáticos	Formulación del criterio de Fisher, demostración matemática y revisión de la notación.
Rodolfo Brandariz	Desarrollo matemático aplicado	Resolución del ejemplo manual, cálculo de matrices de dispersión y explicación de las proyecciones.
Marcelo Bravo	Implementación computacional	Desarrollo y revisión del código Python, implementación del algoritmo y comparación con PCA.
Marcelo Torres	Experimentación y documentación	Experimentos de regularización, análisis de resultados, gráficos y documentación del repositorio.

11. Cronograma de actividades

Actividad	Responsable(s)	Fecha límite	Estado
Revisión y corrección matemática	Elison Sanchez y Rodolfo Brandariz	2/11/2026	En revisión
Verificación de la implementación y pruebas	Marcelo Bravo	2/11/2026	En revisión
Actualización de experimentos y resultados	Marcelo Bravo y Marcelo Torres	2/11/2026	En revisión
Interpretación y discusión de resultados	Todos los integrantes	2/11/2026	En revisión
Actualización de documentos y referencias	Rodolfo Brandariz y Marcelo Torres	7/11/2026	En revisión
Preparación y grabación del video	Todos los integrantes	7/11/2026	Pendiente
Verificación final del repositorio y entrega	Todos los integrantes	9/11/2026	Pendiente

Referencias

[1] R. A. Fisher, “The use of multiple measurements in taxonomic problems,” *Annals of Eugenics*, vol. 7, no. 2, pp. 179–188, 1936, doi: 10.1111/j.1469-1809.1936.tb02137.x.

[2] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York, NY, USA: Springer, 2009, ch. 4.

[3] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer, 2006, sec. 4.1.4.

[4] scikit-learn developers, “Linear and Quadratic Discriminant Analysis,” *scikit-learn documentation*. [En línea]. Disponible: https://scikit-learn.org/stable/modules/lda_qda.html. [Accedido: 2 nov. 2026].

[5] O. Velásquez Castañón, “Separación de clases con el discriminante de Fisher: proyecciones, cocientes de Rayleigh y clasificación,” material de referencia, Álgebra Lineal Aplicada 2026-2, Universidad del Pacífico, Lima, Perú, oct. 2026.