Guion del video: Discriminante lineal de Fisher

Parte 1: Elison Sanchez (0:00 a 3:15)

Título (0:00 a 0:30)

Quién: Elison Sanchez
Pantalla: Diapositiva con el tema, el título y los integrantes.

Hola, qué tal. Somos Elison Sanchez, Rodolfo Brandariz, Marcelo Bravo y Marcelo Torres, y en este video les vamos a contar nuestro proyecto sobre el discriminante lineal de Fisher, que sirve para separar dos clases.

El problema (0:30 a 1:30)

Quién: Elison Sanchez
Pantalla: Nube de dos clases correlacionadas y su proyección sobre la recta de las medias.

Imaginen que tenemos datos de dos grupos y cada dato tiene varias variables. Lo que queremos es quedarnos con un solo número por dato, $y = w^\top x$, pero sin que los grupos se mezclen. Lo primero que se nos ocurrió fue proyectar sobre la recta que une las medias, $d = \mu_1 - \mu_2$. Pero como ven acá, cuando las variables están correlacionadas, las dos clases terminan encimándose. Y otro detalle: si solo maximizamos $(w^\top d)^2$, basta con hacer w más grande para que ese valor crezca todo lo que queramos.

El criterio de Fisher (1:30 a 2:15)

Quién: Elison Sanchez
Pantalla: Diapositiva con $J(w)$.

Entonces, lo que propone Fisher es dividir la separación de las medias entre qué tan dispersa queda cada clase:

$$J(w) = \frac{(w^\top d)^2}{w^\top S_W w}.$$

Abajo tenemos S_W, la dispersión dentro de las clases. Ese denominador es una suma de cuadrados, así que nunca sale negativo. Y algo importante: si multiplicamos w por cualquier número, J no cambia. O sea, lo único que nos importa es hacia dónde apunta w.

Demostración (2:15 a 3:15)

Quién: Elison Sanchez
Pantalla: Pasos de la demostración.

Para encontrar el máximo hacemos el cambio $v = S_W^{1/2} w$. Con eso el cociente queda $(v^\top a)^2 / \|v\|^2$, donde $a = S_W^{-1/2} d$. Por Cauchy–Schwarz, esto es máximo cuando v es paralelo a a, y si regresamos a w nos queda:

$$w \propto S_W^{-1}(\mu_1 - \mu_2).$$

Básicamente, Fisher toma la dirección de las medias y la corrige con S_W^{-1}. Y si los datos no estuvieran correlacionados, S_W sería un múltiplo de la identidad y volveríamos a la recta de las medias.

Parte 2: Rodolfo Brandariz (3:15 a 5:30)

Cociente de Rayleigh y varias clases (3:15 a 4:00)

Quién: Rodolfo Brandariz
Pantalla: Diapositiva con $S_B w = \lambda S_W w$.

Gracias, Elison. Ahora, este mismo criterio también se puede escribir de otra forma. Si llamamos $S_B = dd^\top$, nos queda $w^\top S_B w / w^\top S_W w$, que es un cociente de Rayleigh generalizado, y sus puntos críticos cumplen $S_B w = \lambda S_W w$. Esto nos sirve para el caso de más clases: con K clases, S_B tiene rango a lo más $K-1$, entonces solo podemos sacar hasta $K-1$ direcciones útiles.

Ejemplo a mano (4:00 a 5:30)

Quién: Rodolfo Brandariz
Pantalla: Tabla con los cálculos y la figura `ej_mano.png`.

Para ver que todo esto funciona, hicimos un ejemplo chiquito a mano, con tres puntos por clase. Primero sacamos las medias y la matriz de dispersión, que nos dio $S_W = \begin{pmatrix} 4/3 & 2/3 \\ 2/3 & 4/3 \end{pmatrix}$. Después resolvimos $S_W w = d$ y nos salió w proporcional a $(4, 1)$. Si proyectamos, la primera clase cae en 5, 9 y 10, y la segunda en 19, 23 y 24. El umbral es el punto medio, 15, y el J máximo es 7, que es justo lo que nos da el código. Eso sí, esto solo comprueba que los cálculos están bien; no nos dice qué tan bien clasifica datos nuevos, porque estamos usando los mismos puntos con los que ajustamos.

Parte 3: Marcelo Bravo (5:30 a 7:45)

Implementación y pruebas (5:30 a 6:15)

Quién: Marcelo Bravo
Pantalla: Archivo `src/fisher.py` y ejecución de `pytest`.

Bueno, ahora pasamos al código. Programamos todo en Python con NumPy. Para sacar w resolvemos el sistema con `solve`, sin calcular la inversa. Además armamos 14 pruebas: que salga el ejemplo a mano, que J no cambie al escalar w, que ninguna de 500 direcciones al azar le gane a Fisher, que el código avise si las medias son iguales o si S_W es singular, y que nuestro resultado coincida con el de scikit-learn. Y coincide: la diferencia es del orden de 10^{-16}.

Experimento con datos correlacionados (6:15 a 7:45)

Quién: Marcelo Bravo
Pantalla: `gauss_direcciones.png`, histogramas y tabla de resultados.

Después lo probamos con datos más grandes. Generamos dos clases gaussianas con

covarianza $\Sigma = \begin{pmatrix} 4 & 1.8 \\ 1.8 & 1 \end{pmatrix}$, separamos entrenamiento y prueba antes de ajustar, y lo repetimos 10 veces. Comparamos tres direcciones usando la misma regla de umbral. En prueba, Fisher acertó en promedio 69.5 %, la diferencia de medias 57.9 % y PCA 55.9 %, y Fisher ganó en las 10 repeticiones. Lo de PCA es curioso: elige la dirección donde los datos varían más, que acá es la diagonal de la nube, pero esa dirección no separa las clases porque PCA ni siquiera mira las etiquetas.

Parte 4: Marcelo Torres (7:45 a 10:00)

Regularización (7:45 a 8:45)

Quién: Marcelo Torres
Pantalla: `regularizacion.png`.

Por último, nos preguntamos qué pasa cuando hay pocos datos. Probamos con 30 datos y 40 variables, y ahí S_W se vuelve singular: tiene 12 autovalores nulos y un número de condición de casi 10^{18}. Sin regularizar, el método acierta 51 %, que es prácticamente como lanzar una moneda, y con la pseudoinversa llega a 56 %. Pero si usamos $S_W + \lambda I$, la matriz ya se puede invertir y la exactitud sube hasta 63 %. Lo curioso es que, con λ grande, el resultado queda casi igual al de la diferencia de medias, que es justo lo que dice la teoría: cuando λ crece, w tiende a d. El λ lo elegimos con validación cruzada, usando solo el entrenamiento, para no hacer trampa con los datos de prueba, y con eso llegamos a 62 %.

Conclusiones y limitaciones (8:45 a 9:35)

Quién: Marcelo Torres
Pantalla: Diapositiva de conclusiones.

En resumen, Fisher mejora la dirección de las medias porque toma en cuenta cómo están dispersas las clases, y cuando hay pocos datos hace falta regularizar. Ahora, también tenemos que decir las limitaciones: usamos datos sintéticos con la misma covarianza en las dos clases, que es justo el caso que le conviene a Fisher, y con muy pocos datos Fisher termina pareciéndose a la diferencia de medias. Así que no podemos decir que Fisher siempre sea el mejor.

Cierre (9:35 a 10:00)

Quién: Marcelo Torres
Pantalla: Referencias principales y enlace al repositorio.

Todas las referencias y el código están en nuestro repositorio de GitHub, el enlace está en pantalla. Muchas gracias por vernos.