Guion del video: Discriminante lineal de Fisher

Parte 1: Elison Sanchez (0:00 a 3:00)

Título (0:00 a 0:25)

Quién: Elison Sanchez
Pantalla: Diapositiva con el tema, el título y los integrantes.

Hola, qué tal. Somos Elison Sanchez, Rodolfo Brandariz, Marcelo Bravo y Marcelo Torres, y en este video les vamos a contar nuestro proyecto sobre el discriminante lineal de Fisher, que sirve para separar dos clases.

El problema (0:25 a 1:20)

Quién: Elison Sanchez
Pantalla: Nube de dos clases correlacionadas y su proyección sobre la recta de las medias.

Imaginen que tenemos datos de dos grupos y cada dato tiene varias variables. Lo que queremos es quedarnos con un solo número por dato, $y = w^\top x$, pero sin que los grupos se mezclen. Lo primero que se nos ocurrió fue proyectar sobre la recta que une las medias, $d = \mu_1 - \mu_2$. Pero como ven acá, cuando las variables están correlacionadas, las dos clases terminan encimándose. Y si solo maximizamos $(w^\top d)^2$, basta con agrandar w para que crezca sin límite.

El criterio de Fisher (1:20 a 2:05)

Quién: Elison Sanchez
Pantalla: Diapositiva con $J(w)$.

Entonces, lo que propone Fisher es dividir la separación de las medias entre qué tan dispersa queda cada clase:

$$J(w) = \frac{(w^\top d)^2}{w^\top S_W w}.$$

Abajo tenemos S_W, la dispersión dentro de las clases. Ese denominador es una suma de cuadrados, así que nunca sale negativo. Y algo importante: si multiplicamos w por cualquier número, J no cambia. O sea, lo único que nos importa es hacia dónde apunta w.

Demostración (2:05 a 3:00)

Quién: Elison Sanchez
Pantalla: Pasos de la demostración.

Para encontrar el máximo hacemos el cambio $v = S_W^{1/2} w$. Con eso el cociente queda $(v^\top a)^2 / \|v\|^2$, donde $a = S_W^{-1/2} d$. Por Cauchy–Schwarz, esto es máximo cuando v es paralelo a a, y si regresamos a w nos queda:

$$w \propto S_W^{-1}(\mu_1 - \mu_2).$$

Básicamente, Fisher toma la dirección de las medias y la corrige con S_W^{-1}. Y si los datos no estuvieran correlacionados, S_W sería un múltiplo de la identidad y volveríamos a la recta de las medias.

Parte 2: Rodolfo Brandariz (3:00 a 5:00)

Cociente de Rayleigh y varias clases (3:00 a 3:40)

Quién: Rodolfo Brandariz
Pantalla: Diapositiva con $S_B w = \lambda S_W w$.

Gracias, Elison. Ahora, este mismo criterio también se puede escribir de otra forma. Si llamamos $S_B = dd^\top$, nos queda $w^\top S_B w / w^\top S_W w$, que es un cociente de Rayleigh generalizado, y sus puntos críticos cumplen $S_B w = \lambda S_W w$. Esto nos sirve para el caso de más clases: con K clases, S_B tiene rango a lo más $K-1$, entonces solo podemos sacar hasta $K-1$ direcciones útiles.

Ejemplo a mano (3:40 a 5:00)

Quién: Rodolfo Brandariz
Pantalla: Tabla con los cálculos y la figura `ej_mano.png`.

Para ver que todo esto funciona, hicimos un ejemplo chiquito a mano, con tres puntos por clase. Primero sacamos las medias y la matriz de dispersión, que nos dio $S_W = \begin{pmatrix} 4/3 & 2/3 \\ 2/3 & 4/3 \end{pmatrix}$. Después resolvimos $S_W w = d$ y nos salió w proporcional a $(4, 1)$. Si proyectamos, la primera clase cae en 5, 9 y 10, y la segunda en 19, 23 y 24. El umbral es el punto medio, 15, y el J máximo es 7, que es justo lo que nos da el código. Eso sí, esto solo comprueba que los cálculos están bien, no qué tan bien clasifica datos nuevos.

Parte 3: Marcelo Bravo (5:00 a 7:00)

Implementación y pruebas (5:00 a 5:40)

Quién: Marcelo Bravo
Pantalla: Archivo `src/fisher.py` y ejecución de `pytest`.

Bueno, ahora pasamos al código. Programamos todo en Python con NumPy. Para sacar w resolvemos el sistema con `solve`, sin calcular la inversa. Además armamos pruebas automáticas, 20 en total: que salga el ejemplo a mano, que J no cambie al escalar w, que ninguna de 500 direcciones al azar le gane a Fisher, y que nuestro resultado coincida con el de scikit-learn. Y coincide: la diferencia es del orden de 10^{-16}.

Experimento con datos correlacionados (5:40 a 7:00)

Quién: Marcelo Bravo
Pantalla: `gauss_direcciones.png`, histogramas y tabla de resultados.

Después lo probamos con datos más grandes. Generamos dos clases gaussianas con covarianza $\Sigma = \begin{pmatrix} 4 & 1.8 \\ 1.8 & 1 \end{pmatrix}$, separamos entrenamiento y prueba antes de ajustar, y lo repetimos 10 veces. Comparamos tres direcciones usando la misma regla de umbral. En

prueba, Fisher acertó en promedio 69.5 %, la diferencia de medias 57.9 % y PCA 55.9 %, y Fisher ganó en las 10 repeticiones. Lo de PCA es curioso: elige la dirección donde los datos varían más, que acá es la diagonal de la nube, pero esa dirección no separa las clases porque PCA ni siquiera mira las etiquetas.

Parte 4: Marcelo Torres (7:00 a 10:50)

Regularización con pocos datos (7:00 a 7:45)

Quién: Marcelo Torres
Pantalla: `regularizacion.png`.

Ahora, ¿qué pasa cuando hay pocos datos? Probamos con 30 datos y 40 variables, y ahí S_W se vuelve singular. Sin regularizar, el método acierta 51 %, como lanzar una moneda. Si usamos $S_W + \lambda I$, la matriz ya se puede invertir y la exactitud sube hasta 63 %. Y con λ grande el resultado queda casi igual al de la diferencia de medias, que es lo que dice la teoría: cuando λ crece, w tiende a d. Quédense con esta idea, porque va a volver a aparecer.

Caso aplicado: acciones del S&P 500 (7:45 a 8:35)

Quién: Marcelo Torres
Pantalla: Tabla de las cuatro variables y tabla de la validación externa.

Hasta acá todo era con datos inventados, así que quisimos probar con datos reales. Tomamos 300 acciones del S&P 500 y para cada una calculamos cuatro cosas con los precios de tres años: volatilidad, beta, la caída máxima que tuvo y su apalancamiento. La pregunta es si en el año siguiente la acción cayó más de 30 %. Entrenamos con esas 300 y probamos con 40 acciones nuevas que el modelo nunca vio. ¿Y qué pasó? Fisher, PCA y la diferencia de medias acertaron exactamente lo mismo: 25 de 40. Fisher no ganó. Y eso, en vez de esconderlo, es lo que quisimos entender.

Por qué Fisher no gana aquí (8:35 a 9:50)

Quién: Marcelo Torres
Pantalla: `espectro_w.png` y luego `camino_regularizacion.png`.

La clave está en escribir w con el teorema espectral. Si S_W tiene autovectores u_i y autovalores λ_i, entonces

$$w = \sum_i \frac{u_i^\top d}{\lambda_i}\, u_i.$$

O sea, Fisher divide entre el autovalor: le da más peso a las direcciones donde las clases están menos dispersas. En los datos sintéticos eso era justo lo que hacía falta. Pero acá las tres variables de mercado están muy correlacionadas, y resulta que el 93 % de w viene de un solo autovector, el de “riesgo general”. Las otras tres direcciones tienen más ruido que señal, y Fisher las divide entre autovalores pequeños, así que amplifica ese ruido. Lo que Fisher agrega sobre la diferencia de medias es, básicamente, ruido.

Y acá vuelve la regularización. Si recorremos λ desde cero hasta infinito, w gira 18 grados hasta coincidir con la diferencia de medias, y la exactitud no se mueve. Regularizar no cuesta nada. Además, con 40 acciones de prueba el intervalo de confianza va de 47 % a 76 %, así que ningún método se puede declarar mejor que otro.

Tres clases y conclusiones (9:50 a 10:35)

Quién: Marcelo Torres
Pantalla: `tres_clases_span.png` y diapositiva de conclusiones.

Por último, con tres niveles de riesgo, S_B tiene rango 2 y el problema de autovalores generalizado nos da un plano, el generado por w_1 y w_2, donde las tres clases quedan lo más separadas posible. Así podemos ver en dos dimensiones lo que pasa en cuatro.

En resumen: Fisher llega casi al óptimo cuando hay una dirección de poca varianza con mucha señal. Cuando no la hay, como en las acciones, empata con la diferencia de medias y conviene regularizar. Las limitaciones están en el documento: usamos la lista actual del índice, que deja fuera a las empresas que salieron, un solo año de etiqueta y una prueba pequeña.

Cierre (10:35 a 10:50)

Quién: Marcelo Torres
Pantalla: Referencias principales y enlace al repositorio.

Todo el código, los datos y las referencias están en nuestro repositorio de GitHub; se corre con un solo comando. Muchas gracias por vernos.